

relatorio

July 7, 2026

Universidade de Brasília  
Departamento de Engenharia Elétrica

**Comunicações Móveis - PPGEE UnB**

# **Trabalho 3 - Cell Free Massive MIMO**

Professor: Higo Thaian Pereira da Silva

Aluno: Artur Padovesi Piratelli

Matrícula: 261101032

Brasília  
2026

# 1 Introdução

As redes **Cell-Free Massive MIMO** representam uma evolução das arquiteturas celulares tradicionais ao substituir estações rádio-base de alta potência por um grande número de Pontos de Acesso (Access Points - APs) distribuídos geograficamente e conectados a uma Unidade Central de Processamento (Central Processing Unit - CPU). Nessa arquitetura, todos os APs cooperam para atender simultaneamente todos os Equipamentos de Usuário (User Equipments - UEs), compartilhando os mesmos recursos de tempo e frequência.

Neste notebook é implementado um simulador de uma rede Cell-Free Massive MIMO baseado no modelo proposto por Ngo *et al.* e nos slides sobre Massive MIMO da disciplina de Comunicações Móveis do professor Higo Thaian. O objetivo é avaliar o desempenho do sistema por meio de simulações de Monte Carlo, considerando tanto a variabilidade da geometria da rede quanto as diferentes realizações do canal de pequena escala.

O modelo implementado considera:

- desvanecimento em larga escala utilizando o modelo **Close-In Free-Space (CI)** com sombreamento log-normal;
- desvanecimento Rayleigh para representar o canal de pequena escala;
- estimação de canal por **MMSE** utilizando pilotos ortogonais;
- transmissão em downlink utilizando **Conjugate Beamforming**.

Duas métricas principais de desempenho são analisadas:

- **SINR (Signal-to-Interference-plus-Noise Ratio)**;
- **Taxa alcançável (Achievable Rate)**, obtida a partir da capacidade de Shannon.

Para cada geometria da rede são geradas diversas realizações independentes do canal de pequena escala, mantendo fixas as posições dos APs e UEs. Essa separação permite avaliar isoladamente os efeitos do desvanecimento rápido e da propagação em larga escala.

Ao longo deste notebook serão investigados os impactos de diferentes parâmetros do sistema sobre o desempenho da rede, por meio da comparação das distribuições empíricas (ECDFs) da SINR e da taxa alcançável. Os parâmetros analisados neste documento são:

- número de APs;
- densidade da implantação da rede;
- número de usuários;
- comprimento da sequência de pilotos;
- potência de transmissão.

Sempre que não explicitado o contrário, será utilizada uma configuração de referência (*baseline*), a partir da qual cada parâmetro será variado individualmente para avaliar sua influência sobre o desempenho do sistema. O *baseline* pode ser visto na tabela 1.

**Tabela 1 – Parâmetros utilizados na configuração de referência.**

| Parâmetro                                 | Valor  |
|-------------------------------------------|--------|
| Frequência da portadora ( $f_c$ )         | 3 GHz  |
| Largura de banda ( $B$ )                  | 20 MHz |
| Potência de transmissão dos APs ( $P_d$ ) | 200 mW |

| Parâmetro                                           | Valor                |
|-----------------------------------------------------|----------------------|
| Potência de transmissão dos pilotos ( $P_p$ )       | 100 mW               |
| Figura de ruído                                     | 9 dB                 |
| Temperatura de ruído                                | 296,15 K             |
| Área de simulação                                   | $1000 \times 1000$ m |
| Altura dos APs                                      | 15 m                 |
| Altura dos UEs                                      | 1,65 m               |
| Número de APs ( $M$ )                               | 100                  |
| Número de UEs ( $K$ )                               | 10                   |
| Comprimento da sequência de pilotos ( $\tau_{cf}$ ) | 10                   |

## 2 Implementação

Em geral, a implementação segue exatamente o modelo proposto pelo professor Higo Thaian, com adoções do modelo original quando adequado. Estes casos foram: -  $\Omega$  é ganho de larga escala do canal. As equações (29), (30) e (32) dos slides não considera a conversão de perda de percurso para ganho de percurso; - na equação (36) do documento  $\gamma$  é proporcional a  $\sqrt{P_d}$ , enquanto no modelo original de Ngo, na equação (8),  $\gamma$  é proporcional a  $\sqrt{P_p}$ . A modelagem original foi considerada; - A equação (21) do documento mostra uma versão de SINR diferente do artigo original. A versão original é utilizada no artigo de Ngo, na equação (26), e pode ser escrita da seguinte maneira, seguindo a notação do documento do professor:

$$\text{SINR}_k = \frac{P_d \left| \sum_{m=1}^M \sqrt{\eta_{m,k}} g_{m,k} \hat{g}_{m,k}^* \right|^2}{P_d \sum_{k' \neq k}^K \left| \sum_{m=1}^M \sqrt{\eta_{m,k'}} g_{m,k'} \hat{g}_{m,k'}^* \right|^2 + \sigma_w^2}. \quad (1)$$

## 3 Resultados

```
[1]: from cell_free import CellFree, plot_scenarios
import matplotlib.pyplot as plt
import numpy as np

basic_params = {
    "fc": 3e9, "bw": 20e6,
    "noise_fig_db": 9, "noise_temperature": 296.15,
    "area_dimensions": (1e3, 1e3),
    "ap_h": 15, "ue_h": 1.65,
    "num_ue": 10, "tau_cf": 10,
    "num_ap": 100,
    "pilot_pow_db": 10 * np.log10(0.1),
    "downlink_pow_db": 10 * np.log10(0.2),
}
```

### 3.1 Cenário 1 - Variando o Número de APs

**Tabela 2 – Parâmetros utilizados no Cenário 1.**


| Parâmetro             | Valor         |
|-----------------------|---------------|
| Número de APs ( $M$ ) | 100, 150, 200 |

```
[2]: all_params = [
    {**basic_params, 'num_ap': x} for x in [100, 150, 200]
]
results = []
for par in all_params:
    cell_free_sim = CellFree(**par)
    rng = np.random.default_rng(12331)
    res = cell_free_sim.simulate(rng, 300, 100)
    label = f"M={par['num_ap']}"
    results.append((label, res))

plot_scenarios(results)

plt.show()
```

```
100%|      | 300/300 [00:03<00:00, 79.11it/s]
100%|      | 300/300 [00:05<00:00, 59.43it/s]
100%|      | 300/300 [00:06<00:00, 43.58it/s]
```



Como esperado, conforme  $M$  aumenta, a potência disponível para cada usuário aumenta, levando a uma melhora nas SINR e taxa alcançável.

### 3.2 Cenário 2 - Variando Número de Usuários

Foram utilizados diferentes números de usuários  $K \in \{10, 20, 40\}$ , mantendo sempre  $\tau_{cf} = K$ .

**Tabela 3 – Parâmetros utilizados no Cenário 2.**

| Parâmetro             | Valor           |
|-----------------------|-----------------|
| Número de UEs ( $K$ ) | 10, 20, 40, 100 |

```
[9]: all_params = [
    {**basic_params, "num_ue": 10, "tau_cf": 10},
    {**basic_params, "num_ue": 20, "tau_cf": 20},
    {**basic_params, "num_ue": 40, "tau_cf": 40},
    {**basic_params, "num_ue": 100, "tau_cf": 100},
]


results = []

for par in all_params:
    cell_free_sim = CellFree(**par)
    rng = np.random.default_rng(12331)
    res = cell_free_sim.simulate(rng, 300, 100)

    label = f"K={par['num_ue']}"
    results.append((label, res))

plot_scenarios(results)
plt.show()
```

```
100%|      | 300/300 [00:03<00:00, 80.45it/s]
100%|      | 300/300 [00:07<00:00, 37.71it/s]
100%|      | 300/300 [00:24<00:00, 12.49it/s]
100%|      | 300/300 [02:48<00:00,  1.78it/s]
```



Mesmo que os pilotos se mantenham ortogonais, é possível notar que há uma piora considerável em SINR e taxa alcançável conforme  $K$  aumenta. Além disso, a piora é mais severa para a distribuição de SINR instantânea e taxa alcançável dado CSI perfeito do que para SINR e taxa alcançável estatísticos.

No caso particular com  $K = 100$ , percebe-se que, por 60% do tempo a taxa alcançável com CSI Perfeito não apresenta melhora significativa comparando com CSI estatística.

### 3.3 Cenário 3 - Variando o Número de APs e Área de Cobertura

Com o propósito de manter a densidade aproximadamente constante, a área de cobertura é aumentada conforme  $M$  aumenta.

**Tabela 4 - Parâmetros utilizados no Cenário 3.**

| Parâmetro             | Valor                                                            |
|-----------------------|------------------------------------------------------------------|
| Densidade de APs      | 100 por km <sup>2</sup>                                          |
| Número de APs ( $M$ ) | 100, 150, 200                                                    |
| Área de Cobertura     | $1 \times 1$ , $1.225 \times 1.225$ , $1.414 \times 1.414$<br>km |

```
[11]: all_params = [
    {**basic_params, "num_ap": 100, "area_dimensions": (1000, 1000)},
    {**basic_params, "num_ap": 150, "area_dimensions": (1225, 1225)},
    {**basic_params, "num_ap": 200, "area_dimensions": (1414, 1414)},
]


results = []

for par in all_params:
    cell_free_sim = CellFree(**par)
    rng = np.random.default_rng(12331)
    res = cell_free_sim.simulate(rng, 300, 100)

    label = (
        f"$M={par['num_ap']}$, "
        f"{par['area_dimensions'][0]:.0f}×{par['area_dimensions'][1]:.0f} m"
    )
    results.append((label, res))

plot_scenarios(results)
plt.show()
```

```
100%|      | 300/300 [00:03<00:00, 82.10it/s]
100%|      | 300/300 [00:04<00:00, 60.80it/s]
100%|      | 300/300 [00:06<00:00, 47.75it/s]
```



Diferente do esperado intuitivamente, os resultados do Cenário 3 estão praticamente os mesmos do Cenário 1. Ou seja, um aumento no número de APs no cenário base surte um efeito muito mais significativo que a sua diluição em área.

### 3.4 Cenário 4 - Variando o Número de APs e UEs

Com o propósito de manter a razão  $M/K$  constante, o número de usuários aumenta com mesma proporção com que  $M$  aumenta.

**Tabela 5 - Parâmetros utilizados no Cenário 4.**

| Parâmetro             | Valor             |
|-----------------------|-------------------|
| Razão $M/K$           | 10                |
| Número de APs ( $M$ ) | 20, 100, 150, 200 |
| Número de UEs         | 2, 10, 15, 20     |

```
[16]: all_params = [
    {**basic_params, "num_ap": 20, "num_ue": 2, "tau_cf": 2},
    {**basic_params, "num_ap": 100, "num_ue": 10, "tau_cf": 20},
    {**basic_params, "num_ap": 150, "num_ue": 15, "tau_cf": 20},
    {**basic_params, "num_ap": 200, "num_ue": 20, "tau_cf": 20},
]

results = []

for par in all_params:
    cell_free_sim = CellFree(**par)
    rng = np.random.default_rng(12331)
    res = cell_free_sim.simulate(rng, 300, 100)

    label = (
        f"$M={par['num_ap']}$, "
        f"$K={par['num_ue']}$, "
```



```

        r"$\tau_{\text{cf}}$" f="{par['tau_cf']}"$")
    )
    results.append((label, res))


plot_scenarios(results)
plt.show()

```

```

100%|      | 300/300 [00:00<00:00, 338.98it/s]
100%|      | 300/300 [00:03<00:00, 77.85it/s]
100%|      | 300/300 [00:08<00:00, 37.27it/s]
100%|      | 300/300 [00:14<00:00, 20.07it/s]

```



Com esse caso, é possível notar que o fator mais relevante para manutenção de performance não é densidade de APs por espaço, mas sim a razão  $M/K$ . Para os cenários com  $K \geq 10$ , a performance de todos foi extremamente semelhante. Já o cenário com  $K = 2$  apresentou um resultado consideravelmente diferente, por mais que a razão tenha sido mantida. A taxa alcançável com conhecimento estatístico do canal apresentou ligeira piora quando comparada com os outros cenários, mas com CSI perfeita apresentou melhora considerável. A piora ocorre devido a ausência de *channel hardening*, com a presença de poucos APs, enquanto a melhora ocorre devido à presença de baixíssima interferência no regime instantâneo após considerar inclusive as perdas de percurso.

### 3.5 Cenário 5 - Variando a Potência de Transmissão em Downlink

Neste cenário, avalia-se a influência da potência de transmissão em downlink ( $P_d$ ) sobre o desempenho do sistema Cell-Free Massive MIMO. A potência disponível para transmissão afeta diretamente a potência do sinal recebido pelos usuários e, consequentemente, a relação sinal-interferência-ruído (SINR). Entretanto, como a interferência entre usuários também é proporcional à potência de transmissão, espera-se que o aumento de  $P_d$  resulte em ganhos significativos apenas quando o sistema opera em regime limitado por ruído. Em regimes limitados por interferência, o benefício tende a diminuir, uma vez que tanto o sinal desejado quanto a interferência aumentam na mesma proporção.

Para essa análise, são considerados quatro níveis de potência de transmissão em downlink, variando de 0,1 mW a 100 mW, mantendo-se inalterados os demais parâmetros do cenário base.

**Tabela 6 - Parâmetros utilizados no Cenário 5.**

| Parâmetro                                     | Valor                       |
|-----------------------------------------------|-----------------------------|
| Potência de transmissão em downlink ( $P_d$ ) | 0,1 mW, 1 mW, 10 mW, 100 mW |

```
[14]: all_params = [
    {**basic_params, "downlink_pow_db": 10*np.log10(0.0001)},
    {**basic_params, "downlink_pow_db": 10*np.log10(0.001)},
    {**basic_params, "downlink_pow_db": 10*np.log10(0.01)},
    {**basic_params, "downlink_pow_db": 10*np.log10(0.1)},
]

results = []


for par in all_params:
    cell_free_sim = CellFree(**par)
    rng = np.random.default_rng(12331)
    res = cell_free_sim.simulate(rng, 300, 100)

    power = 10**(par["downlink_pow_db"]/10)*1000
    label = f"$P_d={power}$ mW"

    results.append((label, res))

plot_scenarios(results)
plt.show()
```

```
100%|      | 300/300 [00:03<00:00, 80.86it/s]
100%|      | 300/300 [00:03<00:00, 83.58it/s]
100%|      | 300/300 [00:03<00:00, 85.11it/s]
100%|      | 300/300 [00:03<00:00, 81.54it/s]
```



Os resultados demonstram que, a partir de certa potência, aumentar a potência de transmissão de

dados não auxilia na melhora de SINR e de taxa alcançável. Isso é esperado pois, tanto o sinal desejado quanto a interferência são multiplicados por um mesmo escalar derivado dessa potência. O que ocorre é que, quando  $P_d \gg \sigma_w$ , o canal passa a não depender do ruído, e aumentar essa potência não surte mais efeito.

### 3.6 Cenário 6 - Variando o Comprimento da Sequência de Pilotos

Neste cenário, analisa-se a influência do comprimento da sequência de pilotos ( $\tau_{cf}$ ) na qualidade da estimação do canal e, conseqüentemente, no desempenho do sistema. Como a energia total utilizada na estimação é proporcional ao produto  $\tau_{cf}P_p$ , espera-se que o aumento do comprimento da sequência proporcione melhorias apenas enquanto a estimação estiver limitada pelo ruído. Após determinado ponto, a qualidade da estimação tende a saturar, tornando pouco significativo o aumento adicional de  $\tau_{cf}$ .

Para essa análise, são considerados três comprimentos de sequência de pilotos, mantendo-se constantes todos os demais parâmetros do cenário base.

**Tabela 7 - Parâmetros utilizados no Cenário 6.**

| Parâmetro                                           | Valor       |
|-----------------------------------------------------|-------------|
| Comprimento da sequência de pilotos ( $\tau_{cf}$ ) | 10, 50, 100 |

```
[17]: all_params = [
    {**basic_params, "tau_cf": 10},
    {**basic_params, "tau_cf": 50},
    {**basic_params, "tau_cf": 100},
]


results = []

for i, par in enumerate(all_params):
    cell_free_sim = CellFree(**par)
    rng = np.random.default_rng(12331 + i)
    res = cell_free_sim.simulate(rng, 300, 100)

    label = rf"$\tau_{\text{{cf}}}$={par['tau_cf']}"
    results.append((label, res))

plot_scenarios(results)
plt.show()
```

```
100%|      | 300/300 [00:03<00:00, 79.77it/s]
100%|      | 300/300 [00:03<00:00, 83.34it/s]
100%|      | 300/300 [00:03<00:00, 82.87it/s]
```



É interessante que, alterando  $\tau_{cf}$  no cenário original, todas as curvas se sobrepõem perfeitamente.

Considerando a estimação MMSE do canal, o sinal piloto recebido e projetado para o usuário  $k$  é dado por

$$\tilde{y}_{m,k} = \sqrt{\tau_{cf}P_p} g_{m,k} + w_{m,k}, \quad (2)$$

onde  $w_{m,k}$  representa o ruído complexo gaussiano.

A estimativa do canal é obtida por

$$\hat{g}_{m,k} = c_{m,k} \tilde{y}_{m,k}, \quad (3)$$

onde, considerando que os pilotos são ortogonais,

$$c_{m,k} = \frac{\sqrt{\tau_{cf}P_p} \Omega_{m,k}}{\tau_{cf}P_p \Omega_{m,k} + \sigma_w^2}. \quad (4)$$

A variância da estimativa é

$$\gamma_{m,k} = \mathbb{E}\left\{|\hat{g}_{m,k}|^2\right\} = \sqrt{\tau_{cf}P_p} \Omega_{m,k} c_{m,k}, \quad (5)$$

ou, substituindo a expressão de  $c_{m,k}$ ,

$$\gamma_{m,k} = \frac{\tau_{cf}P_p \Omega_{m,k}^2}{\tau_{cf}P_p \Omega_{m,k} + \sigma_w^2}. \quad (6)$$

Observa-se que, quando

$$\tau_{cf}P_p \Omega_{m,k} \gg \sigma_w^2, \quad (7)$$

tem-se

$$\gamma_{m,k} \approx \Omega_{m,k}, \quad (8)$$

ou seja, a qualidade da estimação torna-se praticamente limitada apenas pelo ganho de larga escala do canal. Nesse regime, aumentar o comprimento da sequência de pilotos não produz melhorias perceptíveis na estimação e, consequentemente, na SINR e na taxa alcançável.

### 3.7 Cenário 7 - Variando a Potência e o Comprimento da Sequência de Pilotos

Neste cenário, busca-se analisar conjuntamente a influência da potência de transmissão dos pilotos ( $P_p$ ) e do comprimento da sequência de pilotos ( $\tau_{cf}$ ) sobre o desempenho do sistema. Conforme discutido anteriormente, o aumento de  $\tau_{cf}$  tende a melhorar a qualidade da estimação do canal apenas enquanto a energia total dedicada aos pilotos é insuficiente para que a estimação atinja seu regime de saturação.

Para investigar esse comportamento, são considerados dois valores de potência de transmissão dos pilotos,  $P_p \in \{0.1, 1\}$  mW, e dois comprimentos de sequência de pilotos,  $\tau_{cf} \in \{10, 100\}$ . Dessa forma, é possível avaliar se o aumento do comprimento da sequência continua proporcionando ganhos quando a potência dos pilotos é reduzida.

**Tabela 8 - Parâmetros utilizados no Cenário 7.**

| Parâmetro                                           | Valor        |
|-----------------------------------------------------|--------------|
| Comprimento da sequência de pilotos ( $\tau_{cf}$ ) | 10, 100      |
| Potência dos pilotos ( $P_p$ )                      | 0,1 mW, 1 mW |

```
[ ]: all_params = [
    /**basic_params,
        "tau_cf": 10,
        "pilot_pow_db": 10*np.log10(0.0001)},

    /**basic_params,
        "tau_cf": 10,
        "pilot_pow_db": 10*np.log10(0.001)},

    /**basic_params,
        "tau_cf": 100,
        "pilot_pow_db": 10*np.log10(0.0001)},

    /**basic_params,
        "tau_cf": 100,
        "pilot_pow_db": 10*np.log10(0.001)},
]

results = []

for i, par in enumerate(all_params):
    cell_free_sim = CellFree(**par)
```

```

rng = np.random.default_rng(12331+i)
res = cell_free_sim.simulate(rng, 300, 100)

power = 10**(par["pilot_pow_db"]/10)*1000
label = rf"$\tau\_text{{cf}}={par['tau_cf']}$, $P_p={power}$ mW"

results.append((label, res))


plot_scenarios(results)
plt.show()

```

```

100%|      | 300/300 [00:03<00:00, 80.10it/s]
100%|      | 300/300 [00:03<00:00, 81.78it/s]
100%|      | 300/300 [00:03<00:00, 82.15it/s]
100%|      | 300/300 [00:03<00:00, 81.28it/s]

```



Como pode ser visto nas equações de estimação de canal, a sua qualidade depende da energia do piloto até um certo limiar, onde  $\tau_{cf}P_p \gg \sigma_w^2$ . Além disso, os casos com  $P_p = 1$ ,  $\tau_{cf} = 10$  e  $P_p = 0.1$ ,  $\tau_{cf} = 100$  possuem mesma energia de piloto  $\tau_{cf}P_p$ , e portanto suas curvas de SINR e taxa alcançável estão sobrepostas.

## 4 Conclusões

Os resultados mostram que o desempenho da rede depende muito mais da razão M/K do que da densidade de APs por área. Isso ficou claro ao comparar os Cenários 1 e 3: aumentar M mantendo a densidade constante (Cenário 3) deu praticamente o mesmo resultado que aumentar M mantendo a área fixa (Cenário 1), enquanto no Cenário 4, cenários com M/K = 10 tiveram desempenho semelhante entre si, mesmo variando M e K bastante — exceto pelo caso  $M = 20$ ,  $K = 2$ , que fugiu do padrão por falta de channel hardening.

Aumentar o número de usuários (Cenário 2) piora SINR e taxa alcançável mesmo com pilotos ortogonais, e essa piora é mais forte no regime instantâneo (CSI perfeito) do que no estatístico, o que faz sentido já que a interferência entre usuários cresce com  $K$ .

Já potência de downlink (Cenário 5) e energia de piloto (Cenários 6 e 7) mostraram o comportamento esperado de saturação: depois de um certo ponto, aumentar  $P_d$  não ajuda porque sinal e interferência crescem juntos, e aumentar  $\tau_{cf}$  ou  $P_p$  não ajuda porque a estimativa de canal já está limitada pelo ganho de larga escala  $\Omega$ . O Cenário 7 deixou isso bem explícito, além de permitir notar outra observação: o que importa é o produto  $\tau_{cf}P_p$ , não os dois separadamente.